

DEL CSV AL GRÁFICO

Limpieza básica de datos y visualización con R y ggplot2

Contexto. Un invernadero registró mediciones de plantas cultivadas bajo tres tratamientos: Control, Fertilizante A y Fertilizante B. La información se encuentra en `invernadero_sucio.csv`, pero contiene algunas inconsistencias de registro. Tu tarea es preparar los datos y generar gráficos que permitan explorarlos.

Objetivo. Importar un CSV, inspeccionarlo, corregir problemas simples y construir visualizaciones con `ggplot2`.

Materiales. R o RStudio, paquete `ggplot2` y archivo `invernadero_sucio.csv`. Se puede trabajar individualmente o en parejas.

Columnas disponibles: `id_planta` (identificador), `tratamiento` (grupo), `dia` (día de medición), `agua_ml` (agua suministrada, mL) y `altura_cm` (altura, cm). Cada fila es un registro de medición.

Reglas de limpieza para esta actividad: una altura o cantidad de agua negativa se considera inválida; los valores vacíos se tratan como datos faltantes; diferencias en mayúsculas/minúsculas y espacios en `tratamiento` no representan grupos nuevos. Dos filas completamente idénticas corresponden a un registro duplicado. No se deben inventar valores para reemplazar los faltantes.

PARTE 1. IMPORTACIÓN Y EXPLORACIÓN

- Carga `invernadero_sucio.csv` en un *data frame* llamado `datos`. Comprueba que las cinco columnas se hayan importado correctamente.
- Muestra las primeras seis filas, el número de filas y columnas, y un resumen de los datos.
- Identifica las variables numéricas y la variable categórica. ¿Qué problemas potenciales observas?

Pista de inicio:

```
datos <- read.csv("invernadero_sucio.csv")
head(datos)
str(datos)
summary(datos)
```

PARTE 2. LIMPIEZA MÍNIMA

Trabaja sobre una copia llamada `limpios`, conservando `datos` sin modificaciones.

- Elimina las filas totalmente duplicadas.
- Unifica los nombres de tratamiento: deben quedar exactamente `Control`, `Fertilizante A` y `Fertilizante B`.
- Descarta los registros que tengan valores vacíos o negativos en `agua_ml` o `altura_cm`.
- Comprueba cuántas filas quedaron y qué tratamientos aparecen. Explica brevemente qué hiciste.

Pistas útiles (no es necesario usarlas todas): `duplicated()`, `trimws()`, `tolower()`, `is.na()`, `table()`, `nrow()`.

PARTE 3. VISUALIZACIÓN

Utiliza `limpios` y el paquete `ggplot2`. Los gráficos deben aparecer en pantalla y contener un título y nombres de ejes comprensibles.

- Histograma.** Representa la distribución de `altura_cm` mediante `geom_histogram()`. Ajusta el número de intervalos o su anchura para que sea legible.
- Boxplot.** Compara `altura_cm` entre los tres tratamientos usando `geom_boxplot()`.
- Dispersión.** Grafica `agua_ml` (eje X) frente a `altura_cm` (eje Y) con `geom_point()`. Distingue los tratamientos mediante el color.

Pista de estructura:

```
library(ggplot2)
ggplot(limpios, aes(x = altura_cm)) +
  geom_histogram(bins = 12) +
  labs(title = "Alturas de las plantas",
       x = "Altura (cm)", y = "Frecuencia")
```

PARTE 4. INTERPRETACIÓN

Responde brevemente (dos o tres líneas por pregunta):

- Según el boxplot, ¿qué tratamiento parece presentar mayores alturas? ¿Puedes asegurar que el fertilizante es la causa solo con este gráfico?
- ¿Se observa alguna relación entre cantidad de agua y altura? ¿Qué otros factores podrían influir?
- ¿Cuál de los tres gráficos te resultó más útil para comparar tratamientos? Justifica.

Desafío opcional. Haz un gráfico de barras con la cantidad de registros válidos por tratamiento, usando `geom_bar()`. ¿Los grupos tienen el mismo tamaño?